

Análisis de Tickets de Supermercado: Mini Proyecto 2025

Tratamiento de datos. Grado en Ciencia de Datos - UV

Ferrer Font, Neus Navarro García, Marta Rodríguez Simón, Alba Aissa Djellouli, Mohammed Balbastre

2025-04-23

Índice

1	Introducción	1
1.1	Contexto	1
1.2	Grupo	2
1.3	Preguntas planteadas	2
2	Material y métodos	2
2.1	Carga de librerías	2
2.2	Carga de datos	3
2.3	Ficheros no leídos	3
2.4	Presentación parcial de los datos	4
3	Resultados	4
4	Conclusiones	4

1 Introducción

En este proyecto se plantea realizar el análisis de tickets del supermercado Mercadona, los cuales fueron recolectados por los estudiantes del grado de Ciencia de datos y otros de cursos anteriores.

1.1 Contexto

Actualmente, las grandes empresas gestionan volúmenes significativos de productos, lo que conlleva elevados costes asociados al transporte y almacenamiento. Por este motivo, resulta fundamental optimizar cada etapa del proceso logístico. Con base en nuestro conocimiento en Big Data, nuestro equipo se enfocará en analizar y comprender las tendencias de los consumidores, con el objetivo de reducir costes operativos.

1.2 Grupo

Nuestro objetivo al responder estas preguntas es profundizar en los hábitos y preferencias reales de los consumidores a partir del análisis de tickets de compra. Al extraer patrones y correlaciones dentro de estos datos, buscamos generar conocimiento útil para anticipar comportamientos, mejorar la planificación comercial y ajustar la oferta a la demanda real. Esta aproximación nos permitirá aportar valor estratégico desde el análisis de datos, con el foco puesto en reducir ineficiencias, mejorar la toma de decisiones y apoyar la sostenibilidad operativa del negocio desde una perspectiva basada en la evidencia.

1.3 Preguntas planteadas

- 1)¿Qué frutas tienen mayor venta en primavera?
- 2)¿Qué eventos locales o festivos generan picos de venta significativos? (Ej. Navidad)
- 3)¿Existen diferencias significativas en las preferencias de compra según zonas (urbana vs rural)?
- 4)¿Qué categorías tienen mayor tendencia a generar compras adicionales (por ejemplo, comprar galletas con café)?
- 5)¿Qué productos muestran mayor consistencia de compra independientemente de cambios en su precio?
- 6)¿Cuántos productos compra en promedio una persona por ticket?
- 7)¿Cuál es el gasto promedio por compra y Cómo varía según el día/hora?
- 8)¿Qué categorías de productos (fruta, verdura...)suelen comprarse juntas con mayor frecuencia?
- 9)¿Hay diferencias de consumo en días laborales vs. fines de semana?
- 10)¿Cuál es el mejor horario para comprar? (Menos concurrencia)
- 11)¿Cuál es el mejor día para comprar? (Menos concurrencia)
- 12)¿Qué mes es mejor para comprar x fruta? (El mes con mayor compra de frutas y verduras)
- 13)¿Cuál ha sido el producto, unitario, más comprado y cuál ha sido el cambio de su precio a lo largo del tiempo?
- 14)¿Cuáles son los productos con mayor facturación total? (Top 5 de los más facturados)
- 15)¿Cómo varían las ventas a lo largo del mes? ¿Hay más compras a fin de mes?
- 16)¿Cuál es la tasa de personas que al comprar, tienen parking? (Compras con parking/Total de compras)
- 17)¿Qué productos aparecen con mayor frecuencia en los tickets de alto valor (€)?
- 18)¿Qué combinaciones de productos se repiten con más frecuencia en una misma compra?

2 Material y métodos

2.1 Carga de librerías

Para la carga de librerías, haremos uso del paquete pacman de R, que es eficiente para la carga e instalación de las mismas. En este proyecto, utilizaremos las librerías ‘pdfutils’, ‘tidyverse’, ‘readxl’, ‘lubridate’, ‘visdat’ y ‘knitr’.

2.2 Carga de datos

Todos nuestros datos están almacenados en la carpeta *.data*, y fueron obtenidos posteriormente desde un repositorio en la nube. Todos los ficheros contenidos en esta carpeta están en formato *.pdf*.

Antes de empezar con la extracción de los datos, fue necesario preguntarse: ¿Como vamos a almacenar la información? ¿Qué información queremos almacenar? Adicionalmente, para evitar problemas con la extracción y lectura de datos desde los ficheros pdf al entorno de R, se estableció que lo mejor sería tratar todos los datos como caracteres. Una vez que todos los datos fueran leídos correctamente, se podría hacer la conversión al tipo de dato correspondiente.

Nota: A lo largo de la extracción de los datos, se implementaron funciones para ser recursivos, además de facilitar la lectura del código y hacer un barrido completo sobre los ficheros.

Dentro de cada fichero, encontramos dos partes fundamentales. La primera, es el encabezado. Contiene información sobre la compra en general. Por ejemplo, reúne datos como la ubicación de la tienda, fecha y hora de compra, y número de ticket. En la segunda parte, nos encontramos con el bloque de los productos. En ella se describe el producto comprado, la cantidad y el importe pagado.

Para la lectura de los productos, identificamos dos filtros esenciales. El primero, es si el ticket incluía parking o no. Este ‘producto’ estaba listado al final, lo que nos permitía de alguna forma reducir el listado de productos e identificar si había o no parking.

El segundo filtro, permitía saber si se compró pescado o no. Este filtro fue de utilidad dado que por la naturaleza de negocio de Mercadona, los tickets y los productos vienen clasificados en 3 categorías:

- Venta por unidad.
- Venta al peso, pescado.
- Venta al peso, frutas y verduras.

Si en el ticket se registró la compra de pescado, ya podíamos establecer que a partir de ese filtro, los productos que estuvieran por debajo de esa línea, serían al peso. Y los que no, serían por unidad.

Una vez que se identificara el tipo de producto, unitario o al peso, ya sería más fácil identificar la categoría a la que pertenece, por el formato en que fue registrado el producto en el ticket.

- Patron producto unitario: Cantidad(1), descripción, importe
- Patron producto unitario: Cantidad(+1), descripción, precio unitario, importe
- Patron pescado: descripción, peso, precio unitario, importe
- Patron frutas y verduras: Cantidad(1), descripción, peso, precio unitario, importe

2.3 Ficheros no leídos

Solo aquellos ficheros que estuvieran con el formato correcto, serían tratados. Es decir, aquellos ficheros que tuvieran un escaner, foto u otro formato de factura distinto al formato de Mercadona, no serían tratados. Para identificarlos y corroborar su contenidos, hemos almacenado el nombre del fichero en un dataframe diferente.

Adicional, para verificar la lectura de los datos, se filtró el dataframe que contiene toda la información de los productos comprados por los valores NA; si la carga se hizo correctamente, el valor de NA dentro del dataframe debería ser 0.

Cuadro 1: Tabla de tiendas registradas

IdTienda	Direccion	CodigoPostal	Municipio	Telefono
2916	CTRA. GARRUCHA A VERA S/N	04630	GARRUCHA	950133380
2233	AVDA. VALENCIA 41	03830	MURO	966516066
4530	C/ ALICANTE 83	03801	ALCOI/ALCOY	965366422
3075	C/ MENORCA (C.C. AQUA) 19	46023	VALENCIA	963319378
3095	C/ VALENCIA S/N	03178	BENIJOFAR	966713008
4478	AVDA. DEL TEXTIL 21	46870	ONTINYENT	961484834
4347	C/ PERIODISTA AZZATI 26	46520	SAGUNT/SAGUNTO	961485847
4583	C/ MANUEL CANDELA 16	46021	VALENCIA	961624385
3957	C/ PINTOR MAELLA 3	46023	VALENCIA	962564516
2473	AVDA. CARDENAL BENLLOCH 91	46021	VALENCIA	963612915

Cuadro 2: Tabla de productos leídos

Fecha	IdTienda	IdFactura	Hora	Producto	Cantidad	PrecioUnitario	Importe	Ti
25/11/2023	2916	520925	09:09	DONACIÓN	5	1,00	5,00	U
25/11/2023	2916	520925	09:09	BARREÑO	1	2,20	2,20	U
25/11/2023	2916	520925	09:09	PALO ANTIDESLIZANTE	3	1,90	5,70	U
25/11/2023	2916	520925	09:09	MULTIUSOS	1	2,55	2,55	U
25/11/2023	2916	520925	09:09	AGUA MINERAL	2	0,73	1,46	U
25/11/2023	2916	520925	09:09	B.BASURA EXT.C.FÁCIL	2	1,60	3,20	U
25/11/2023	2916	520925	09:09	ESCURRE FÁCIL	1	2,85	2,85	U
25/11/2023	2916	520925	09:09	CUBO FREGAR C/RUEDAS	1	3,85	3,85	U
25/11/2023	2916	520925	09:09	FRIEGASUELOS PINO	1	0,95	0,95	U
25/11/2023	2916	520925	09:09	FIBRAS CRUZADAS	2	2,10	4,20	U
25/11/2023	2916	520925	09:09	LOTE BAYETAS SUAVES	1	1,20	1,20	U
25/11/2023	2916	520925	09:09	FREGONA HILO MIR.	1	2,80	2,80	U
25/11/2023	2916	520925	09:09	LOTE 3 BAYETAS MICRO	1	1,80	1,80	U
01/12/2023	2233	451305	14:41	1/2 POLLO PARTIDO	1	4,34	4,34	U
01/12/2023	2233	451305	14:41	1/2 CONEJO TROCEADO	1	5,13	5,13	U

2.4 Presentación parcial de los datos

Esta es una representación sobre cómo se almacenaron los datos para empezar a trabajar sobre ellos. En la Tabla 1 podemos ver todas las tiendas en las que se han hecho las compras. En total, se han registrado 35 tiendas.

En la siguiente Tabla 2 se muestran los productos que fueron leídos, identificando por ejemplo el ticket de compra, la fecha, el tipo de producto, entre otros.

3 Resultados

4 Conclusiones