

Análisis de Tickets de Supermercado: Mini Proyecto 2025

Tratamiento de datos. Grado en Ciencia de Datos - UV

2025-05-08

Neus Ferrer Font, Marta Navarro García, Alba Rodríguez Simón, Mohammed Aissa Djellouli

Héctor Balbastre Aparisi, Joan Ruiz Ripoll, Carlos Santiago Martinez Torres

1 Introducción

En este proyecto se plantea realizar el análisis de tickets del supermercado Mercadona, los cuales fueron recolectados por los estudiantes del grado de Ciencia de datos y otros de cursos anteriores.

1.1 Contexto

Actualmente, las grandes empresas gestionan volúmenes significativos de productos, lo que conlleva elevados costes asociados al transporte y almacenamiento. Por este motivo, resulta fundamental optimizar cada etapa del proceso logístico. Con base en nuestro conocimiento en Big Data, nuestro equipo se enfocará en analizar y comprender las tendencias de los consumidores, con el objetivo de reducir costes operativos.

1.2 Grupo

Nuestro objetivo al responder estas preguntas es profundizar en los hábitos y preferencias reales de los consumidores a partir del análisis de tickets de compra. Al extraer patrones y correlaciones dentro de estos datos, buscamos generar conocimiento útil para anticipar comportamientos, mejorar la planificación comercial y ajustar la oferta a la demanda real. Esta aproximación nos permitirá aportar valor estratégico desde el análisis de datos, con el foco puesto en reducir ineficiencias, mejorar la toma de decisiones y apoyar la sostenibilidad operativa del negocio desde una perspectiva basada en la evidencia.

1.3 Preguntas planteadas

1. ¿Qué combinaciones de productos se compran con mayor frecuencia en una misma factura?
2. ¿Qué productos mantienen un volumen de ventas estable, independientemente de cambios en su precio unitario?
3. ¿Cuál es el número promedio de productos por ticket y el gasto promedio por compra, según el día y la hora?
4. ¿Qué patrones de compra se observan hacia inicio/fin de mes? ¿Cuántas compras incluyen parking?
5. ¿Cuáles son los 5 productos, de los vendidos por unidades, con más ventas? ¿Cuántas unidades de cada uno se han vendido?
6. Si consideramos la categoría de FRUTAS Y VERDURAS. Cuáles son los 5 productos más vendidos? ¿Cuántos kilos se han vendido de cada uno de estos productos?

7. Si consideramos la categoría de PESCADO. Cuáles son los 5 productos más vendidos? ¿Cuántos kilos se han vendido de cada uno de estos productos?
8. Muestra mediante un gráfico de líneas como ha variado el precio por kilo de las bananas y los plátanos en los tickets disponibles, a lo largo del tiempo.
9. ¿Cuál es la procedencia de los tickets? ¿Qué ciudad/ pueblo tiene un mayor número de tickets?
10. Muestra mediante un diagrama el número de tickets recogidos cada día de la semana. ¿Si tuvieses que cerrar un día entre semana qué día lo harías?

2 Material y métodos

2.1 Carga de librerías

Para la carga de librerías, haremos uso del paquete `pacman` de R, que es eficiente para la carga e instalación de las mismas. En este proyecto, utilizaremos las librerías `pdfutils`, `tidyverse`, `readxl`, `lubridate`, `visdat`, entre otras.

2.2 Carga de datos

Todos nuestros datos están almacenados en la carpeta *data*, y fueron obtenidos desde un repositorio en la nube. Todos los ficheros contenidos en esta carpeta están en formato *pdf*.

Antes de empezar con la extracción de los datos, fue necesario preguntarse: ¿Qué información queremos almacenar? ¿Cómo vamos a almacenar la información para responder a las preguntas planteadas? Adicionalmente, para evitar problemas con la extracción y lectura de datos desde los ficheros *pdf* al entorno de R, se estableció que lo mejor sería tratar todos los datos como caracteres. Una vez que todos los datos fueran leídos correctamente, se podría hacer la conversión al tipo de dato correspondiente.

Nota: A lo largo de la extracción de los datos, se implementaron funciones para ser recursivos, además de facilitar la lectura del código y hacer una carga completa (barrido) de los datos contenidos en los ficheros.

Dentro de cada fichero, encontramos dos partes fundamentales. La primera, es el encabezado. Contiene información sobre la compra en general. Por ejemplo, reúne datos como la ubicación de la tienda, fecha y hora de compra, y número de ticket. En la segunda parte, nos encontramos con el bloque de los productos. En ella se describe el producto comprado, la cantidad y el importe pagado.

Para la lectura de los productos, identificamos dos filtros esenciales. El primero, es si el ticket incluía parking o no. Este ‘producto’ estaba listado al final, lo que nos permitía de alguna forma reducir el listado de productos e identificar si había o no parking.

El segundo filtro, permitía saber si se compró pescado o no. Este filtro fue de gran utilidad dado que por la naturaleza de negocio de Mercadona, los tickets y los productos vienen clasificados en 2 categorías: *Venta por unidad* y *veta al peso* para pescado y, frutas y verduras.

Si en el ticket se registró la compra de pescado, ya podíamos establecer que a partir de ese filtro, los productos que estuvieran por debajo de esa línea, serían al peso. Y los que no, serían por unidad. Una vez que se identificara el tipo de producto, unitario o al peso, ya sería más fácil identificar la categoría a la que pertenece, por el formato en que fue registrado el producto en el ticket.

2.3 Ficheros no leídos

Solo aquellos ficheros que estuvieran con el formato correcto, serían tratados. Es decir, aquellos ficheros que tuvieran un escaner, foto u otro formato de factura distinto al formato de Mercadona, no serían tratados. Para identificarlos y corroborar su contenido, hemos almacenado el nombre del fichero en un dataframe diferente *NoLeído*.

Cuadro 1: Tabla de tiendas leídas

IdTienda	Direccion	CodigoPostal	Municipio	Telefono
2916	CTRA. GARRUCHA A VERA S/N	04630	GARRUCHA	950133380
2233	AVDA. VALENCIA 41	03830	MURO DE ALCOY	966516066
4530	C/ ALICANTE 83	03801	ALCOI/ALCOY	965366422
3075	C/ MENORCA (C.C. AQUA) 19	46023	VALENCIA	963319378
3095	C/ VALENCIA S/N	03178	BENIJOFAR	966713008
4478	AVDA. DEL TEXTIL 21	46870	ONTINYENT	961484834
4347	C/ PERIODISTA AZZATI 26	46520	SAGUNT/SAGUNTO	961485847
4583	C/ MANUEL CANDELA 16	46021	VALENCIA	961624385
3957	C/ PINTOR MAELLA 3	46023	VALENCIA	962564516
2473	AVDA. CARDENAL BENLLOCH 91	46021	VALENCIA	963612915

Cuadro 2: Tabla de productos leídos

IdFactura	DescripcionProducto	Cantidad	PrecioUnitario	ImporteProducto	TipoProducto
520925	DONACIÓN	5	1,00	5,00	Unitario
520925	BARREÑO	1	2,20	2,20	Unitario
520925	PALO ANTIDESLIZANTE	3	1,90	5,70	Unitario
520925	MULTIUSOS	1	2,55	2,55	Unitario
520925	AGUA MINERAL	2	0,73	1,46	Unitario
520925	B.BASURA EXT.C.FÁCIL	2	1,60	3,20	Unitario
520925	ESCURRE FÁCIL	1	2,85	2,85	Unitario
520925	CUBO FREGAR C/RUEDAS	1	3,85	3,85	Unitario
520925	FRIEGASUELOS PINO	1	0,95	0,95	Unitario
520925	FIBRAS CRUZADAS	2	2,10	4,20	Unitario

2.4 Presentación parcial de los datos

Esta es una representación sobre cómo se almacenaron los datos para empezar a trabajar sobre ellos. En la Tabla 1 podemos ver todas las tiendas en las que se han hecho las compras. En total, se han registrado 34 tiendas.

En la Tabla 2 se muestran los productos que fueron leídos, identificando por ejemplo el ticket de compra, el tipo de producto, cantidad, entre otros.

3 Limpieza de datos

Para garantizar la fiabilidad de los datos y realizar su posterior análisis, es importante realizar el proceso de limpieza de datos. Podremos ver los valores NA, máximos, mínimos, y evaluar las diferentes características.

3.1 Valores vacíos

En principio, dada la naturaleza del ejercicio, de extracción y carga de los datos, no deberían haber valores nulos. Sin embargo, es necesario verificar, especialmente con los dataframes que queremos analizar: Producto y Tienda.

3.2 Problemas con tipos de datos

Con *glimpse* podemos ver algunos datos del dataframe, además de comprobar que cada columna tenga su tipo adecuado. En el dataframe de tienda, podríamos poner tanto el id, el código postal, y el teléfono como números enteros, pero, ya que no tendría sentido realizar operaciones propias de los números enteros con estos datos, no será necesario.

Con los dataframes Compra y Producto, no podemos hacer lo mismo. Las variables como *Fecha*, *ImporteTotal*, *Cantidad* y *PrecioUnitario*, deben tener el dato correspondiente para realizar las operaciones necesarias. Por ejemplo, dentro de las variables numéricas, es importante sustituir las comas por puntos para identificar los decimales y transformar correctamente el dato. Por último, el *TipoProducto*, *Parking* y la variable *Tarjeta*, que serán de tipo categórico.

Para finalizar hacemos una verificación sobre los valores repetidos. En principio, no deberían haber valores repetidos, ya que al hacer el registro de los datos, se evitó este problema. Sin embargo, usando *unique* podemos asegurarnos.

4 Resultados

4.1 Análisis de variables

Una vez tenemos limpios los datos, procedemos a analizarlos. Dada la naturaleza de los datos y del desarrollo del trabajo, el análisis de las variables y las relaciones entre ellas, las veremos en profundidad en los apartados siguientes. Sin embargo, para tener un acercamiento a los datos, podemos ver:

```
##      Fecha                                IdTienda                IdFactura
## Min.      :2023-11-25 09:09:00.00    Length:290                Length:290
## 1st Qu.   :2024-04-14 02:21:00.00    Class :character          Class :character
## Median   :2024-09-19 20:08:00.00    Mode  :character          Mode  :character
## Mean     :2024-08-27 02:31:47.38
## 3rd Qu.  :2025-01-08 14:11:15.00
## Max.     :2025-03-15 16:14:00.00
## Parking   Tarjeta   ImporteTotal
## FALSE:261   TRUE:290   Min.      : 0.43
## TRUE : 29                                1st Qu.: 20.16
##                                           Median : 37.05
##                                           Mean   : 45.88
##                                           3rd Qu.: 59.19
##                                           Max.   :234.20

##      IdFactura      DescripcionProducto      Cantidad      PrecioUnitario
## Length:4807        Length:4807          Min.      :0.054    Min.      : 0.150
## Class :character    Class :character    1st Qu.:1.000    1st Qu.: 1.390
## Mode  :character    Mode  :character    Median :1.000    Median : 2.030
##                                           Mean   :1.129    Mean   : 2.591
##                                           3rd Qu.:1.000    3rd Qu.: 3.070
##                                           Max.   :8.000    Max.   :31.330
## ImporteProducto      TipoProducto
## Min.      : 0.150    Fruta y verdura: 354
## 1st Qu.: 1.450    Pescado          : 46
## Median : 2.190    Unitario         :4407
## Mean   : 2.765
## 3rd Qu.: 3.330
## Max.   :31.330
```

Sin embargo, para familiarizarnos con los datos, analizaremos los precios medios de los productos, dado que han variado a lo largo del tiempo, y las palabras que más se repiten en la descripción de los productos (Figura ??). En nuestro estudio encontramos dos variables numéricas que se encuentran en el dataframe de los productos comprados. Realizando el análisis sobre la variable *PrecioUnitario*, vemos su distribución en el gráfico ??, donde la mayoría de los precios promedio de Mercadona no superan los 10 EUR. Sin embargo, considerando la detección por la regla de boxplot, ya que no se sigue una distribución normal, aquellos valores por debajo de 1.4 y por arriba de 3.12 son considerados como outliers.

4.2 Continuación análisis...

5 Conclusiones