

Análisis de Tickets de Supermercado: Mini Proyecto 2025

Tratamiento de datos. Grado en Ciencia de Datos - UV

2025-05-12

Neus Ferrer Font, Marta Navarro García, Alba Rodríguez Simón, Mohammed Aissa Djellouli

Héctor Balbastre Aparisi, Joan Ruiz Ripoll, Carlos Santiago Martinez Torres

1 Introducción

En este proyecto se plantea realizar el análisis de tickets del supermercado Mercadona, los cuales fueron recolectados por los estudiantes del grado de Ciencia de datos y otros de cursos anteriores.

1.1 Contexto

Actualmente, las grandes empresas gestionan volúmenes significativos de productos, lo que conlleva elevados costes asociados al transporte y almacenamiento. Por este motivo, resulta fundamental optimizar cada etapa del proceso logístico. Con base en nuestro conocimiento en Big Data, nuestro equipo se enfocará en analizar y comprender las tendencias de los consumidores, con el objetivo de reducir costes operativos.

1.2 Grupo

Nuestro objetivo al responder estas preguntas es profundizar en los hábitos y preferencias reales de los consumidores a partir del análisis de tickets de compra. Al extraer patrones y correlaciones dentro de estos datos, buscamos generar conocimiento útil para anticipar comportamientos, mejorar la planificación comercial y ajustar la oferta a la demanda real. Esta aproximación nos permitirá aportar valor estratégico desde el análisis de datos, con el foco puesto en reducir ineficiencias, mejorar la toma de decisiones y apoyar la sostenibilidad operativa del negocio desde una perspectiva basada en la evidencia.

2 Material y métodos

2.1 Carga de librerías

Para la carga de librerías, haremos uso del paquete pacman de R, que es eficiente para la carga e instalación de las mismas. En este proyecto, utilizaremos las librerías pdfutils, tidyverse, readxl, lubridate, visdat, entre otras.

2.2 Carga de datos

Todos nuestros datos están almacenados en la carpeta *data*, y fueron obtenidos desde un repositorio en la nube. Todos los ficheros contenidos en esta carpeta están en formato *pdf*.

Antes de empezar con la extracción de los datos, fue necesario preguntarse: ¿Qué información queremos almacenar? ¿Cómo vamos a almacenar la información para responder a las preguntas planteadas? Adicionalmente, para evitar problemas con la extracción y lectura de datos desde los ficheros *pdf* al entorno de R, se estableció que lo mejor sería tratar todos los datos como caracteres. Una vez que todos los datos fueran leídos correctamente, se podría hacer la conversión al tipo de dato correspondiente.

Nota: A lo largo de la extracción de los datos, se implementaron funciones para ser recursivos, además de facilitar la lectura del código y hacer una carga completa (barrido) de los datos contenidos en los ficheros.

Dentro de cada fichero, encontramos dos partes fundamentales. La primera, es el encabezado. Contiene información sobre la compra en general. Por ejemplo, reúne datos como la ubicación de la tienda, fecha y hora de compra, y número de ticket. En la segunda parte, nos encontramos con el bloque de los productos. En ella se describe el producto comprado, la cantidad y el importe pagado.

Para la lectura de los productos, identificamos dos filtros. El primero, es si el ticket incluía parking o no. Este ‘producto’ estaba listado al final, lo que nos permitía de alguna forma reducir el listado de productos e identificar si había o no parking.

El segundo filtro, permitía saber si se compró pescado o no. Este filtro fue de gran utilidad dado que por la naturaleza de negocio de Mercadona, los tickets y los productos vienen clasificados en 2 categorías: *Venta por unidad* y *veta al peso* para pescado y, frutas y verduras.

Si en el ticket se registró la compra de pescado, ya podíamos establecer que a partir de ese filtro, los productos que estuvieran por debajo de esa línea, serían al peso. Y los que no, serían por unidad. Una vez que se identificara el tipo de producto, unitario o al peso, ya sería más fácil identificar la categoría a la que pertenece, por el formato en que fue registrado el producto en el ticket.

2.3 Ficheros no leídos

Solo aquellos ficheros que estuvieran con el formato correcto, serían tratados. Es decir, aquellos ficheros que tuvieran un escaner, foto u otro formato de factura distinto al formato de Mercadona, no serían tratados. Para identificarlos y corroborar su contenido, hemos almacenado el nombre del fichero en un dataframe diferente *NoLeído*.

2.4 Presentación parcial de los datos

Esta es una representación sobre cómo se almacenaron los datos para empezar a trabajar sobre ellos. En la Tabla 1 podemos ver todas las tiendas en las que se han hecho las compras. En total, se han registrado 34 tiendas.

En la Tabla 2 se muestran los productos que fueron leídos, identificando por ejemplo el ticket de compra, el tipo de producto, cantidad, entre otros.

3 Limpieza de datos

3.1 Valores NA

En principio, dada la naturaleza del ejercicio, de extracción y carga de los datos, no deberían haber valores nulos o NA. Sin embargo, es necesario verificar, especialmente con los dataframes que queremos analizar: Producto y Tienda.

Cuadro 1: Tabla de tiendas leídas

IdTienda	Direccion	CodigoPostal	Municipio	Telefono
2916	CTRA. GARRUCHA A VERA S/N	04630	GARRUCHA	950133380
2233	AVDA. VALENCIA 41	03830	MURO DE ALCOY	966516066
4530	C/ ALICANTE 83	03801	ALCOI/ALCOY	965366422
3075	C/ MENORCA (C.C. AQUA) 19	46023	VALENCIA	963319378
3095	C/ VALENCIA S/N	03178	BENIJOFAR	966713008
4478	AVDA. DEL TEXTIL 21	46870	ONTINYENT	961484834
4347	C/ PERIODISTA AZZATI 26	46520	SAGUNT/SAGUNTO	961485847
4583	C/ MANUEL CANDELA 16	46021	VALENCIA	961624385
3957	C/ PINTOR MAELLA 3	46023	VALENCIA	962564516
2473	AVDA. CARDENAL BENLLOCH 91	46021	VALENCIA	963612915

Cuadro 2: Tabla de productos leídos

IdFactura	DescripcionProducto	Cantidad	PrecioUnitario	ImporteProducto	TipoProducto
520925	DONACIÓN	5	1,00	5,00	Unitario
520925	BARREÑO	1	2,20	2,20	Unitario
520925	PALO ANTIDESLIZANTE	3	1,90	5,70	Unitario
520925	MULTIUSOS	1	2,55	2,55	Unitario
520925	AGUA MINERAL	2	0,73	1,46	Unitario
520925	B.BASURA EXT.C.FÁCIL	2	1,60	3,20	Unitario
520925	ESCURRE FÁCIL	1	2,85	2,85	Unitario
520925	CUBO FREGAR C/RUEDAS	1	3,85	3,85	Unitario
520925	FRIEGASUELOS PINO	1	0,95	0,95	Unitario
520925	FIBRAS CRUZADAS	2	2,10	4,20	Unitario

3.2 Problemas con tipos de datos

Con *glimpse* podemos ver algunos datos del dataframe, además de comprobar que cada columna tenga su tipo adecuado. En el dataframe de tienda, podríamos poner tanto el id, el código postal, y el teléfono como números enteros, pero, ya que no tendría sentido realizar operaciones propias de los números enteros con estos datos, no será necesario.

Con los dataframes Compra y Producto, no podemos hacer lo mismo. Las variables como *Fecha*, *ImporteTotal*, *Cantidad* y *PrecioUnitario*, deben tener el dato correspondiente para realizar las operaciones necesarias. Por ejemplo, dentro de las variables numéricas, es importante sustituir las comas por puntos para identificar los decimales y transformar correctamente el dato. Por último, el *TipoProducto*, *Parking* y la variable *Tarjeta*, que serán de tipo categórico.

Para finalizar hacemos una verificación sobre los valores repetidos. En principio, no deberían haber valores repetidos, ya que al hacer el registro de los datos, se evitó este problema. Sin embargo, usando *unique* podemos asegurarnos.

4 Resultados

4.1 Análisis de variables

Una vez tenemos limpios los datos, procedemos a analizarlos. Debemos tener en cuenta que dada la naturaleza de los datos y el desarrollo del trabajo, el análisis de las variables y las relaciones entre ellas, las veremos en profundidad en los apartados siguientes. Sin embargo, para tener un acercamiento a los datos, se puede ver la Figura 1.




Figura 1: Análisis de variables

Mercadona se caracteriza por ofrecer productos a precios bajos. Por ejemplo, podemos ver como los importes por productos, tienen un sesgo por derecha, hacia precios menores a los 10 euros, donde su media no supera los 5 euros. Por otro lado, los productos que más se han de comprar en Mercadona, son los unitarios. Los pescados y, frutas y verdura, no tienen la misma proporción.

A pesar de que no se presentan gran cantidad de datos para ver la variación de los precios en los productos por año, y su comportamiento y/o frecuencia de compra por cada mes, vemos que hay una tendencia a comprar entre los primeros 4 meses del año y el final.

4.2 Preguntas planteadas

1. ¿Qué combinaciones de productos se compran con mayor frecuencia en una misma factura?

Para las combinaciones de productos, será necesario saber el *id de factura* y la *descripción del producto*. Una vez identificados, generamos todas las combinaciones entre los productos por factura, para saber la frecuencia en todas las facturas.

En la Figura 2, vemos que la combinación de productos que más se repite es *ALMENDRA NATURAL + CACAHUETE CHOCOLATE*, con un total de 16 veces. Por lo tanto, el 5.51% de las compras analizadas presentan esta combinación.




Figura 2: Combinaciones de productos más frecuentes

2. ¿Qué productos mantienen un volumen de ventas estable, independientemente de cambios en su precio unitario?

Para determinar los productos que mantienen un volumen de ventas estable, analizaremos el *cv_precio*, que es el coeficiente de variación del precio. Mide la variabilidad relativa del precio del producto (desviación estándar sobre media). Cuanto más bajo, más estable es el precio. También, la *correlación* entre el precio unitario y la cantidad vendida. Mide si las ventas aumentan o disminuyen cuando cambia el precio.

En la Figura 3, se visualiza cómo varían las ventas (Cantidad) según el precio (PrecioUnitario) para los 5 productos más estables. Como estos productos tienen precios muy constantes (bajo *cv_precio*), los puntos están cercanos al eje X. Las líneas rojas muestran la tendencia general: si sube o baja la venta cuando cambia el precio.

En general, la mayoría de los productos tienen precios bastante estables (*cv_precio* < 0.1), lo cual es bueno para control de precios. Las correlaciones son muy bajas, cercanas a 0. Esto sugiere que, para estos productos, el precio no influye fuertemente en la cantidad vendida.

3. ¿Cuál es el número promedio de tickets por hora y el gasto promedio por compra, según el día y la hora?




Figura 3: Relación precio-cantidad para productos con ventas estables




Figura 4: Análisis de tickets y gasto medio

Cuadro 3: Compras que incluyen parking

Parking	Total compras
FALSE	261
TRUE	29

En la Figura 4 ...

4. ¿Qué patrones de compra se observan hacia inicio/fin de mes? ¿Cuántas compras incluyen parking?




Figura 5: Patrones de compra por epoca de mes

En la Figura 5 ...

En la Tabla 3 vemos que el 90% de las compras no registran parking.

- ¿Cuáles son los 5 productos, de los vendidos por unidades, con más ventas? ¿Cuántas unidades de cada uno se han vendido?

En la Figura 6 ...

- Si consideramos la categoría de FRUTAS Y VERDURAS, ¿cuáles son los 5 productos más vendidos? ¿Cuántos kilos se han vendido de cada uno de estos productos?

En la Figura 7 ...

- Si consideramos la categoría de PESCADO, ¿Cuáles son los 5 productos más vendidos? ¿Cuántos kilos se han vendido de cada uno de estos productos?

Para saber cuáles son los 5 productos más vendidos considerando únicamente la categoría pescado, debemos primero filtrar los datos para quedarnos solamente con la categoría *TipoProducto* y que esta contenga el valor de "Pescado". Seguidamente calcularemos los kilos totales vendidos de cada producto y, por último mediante una suma nos quedaremos con los 5 productos más vendidos.




Figura 6: Top 5 productos unitarios mas vendidos




Figura 7: Top 5 frutas y verduras mas vendidas

Cuadro 4: Analisis categoria PESCADO

DescripcionProducto	veces_comprado	kilos_totales
BACALADILLA	5	5.782
SEPIA FRESCA	5	2.642
SEPIA LONJA	4	2.792
LENGUADO FRESC EUROP	3	1.248
SEPIA SUCIA REFRIG	3	2.402

En la Tabla 4, los 5 productos más vendidos de la categoría pescado son la bacaladilla con una venta de 5.782 kg, la sepia fresca con 2.642 kg vendidos, la sepia lonja con 2.792 kg vendidos, el lenguado fresco con 1.248 kg vendidos y por último la sepia sucia, con 2.402 kg vendidos.

8. Muestra mediante un gráfico de líneas como ha variado el precio por kilo de las bananas y los plátanos en los tickets disponibles, a lo largo del tiempo.

Primero debemos unir las dos tablas “Compra” y “Producto” ya que en una se encuentra la descripción del producto y en otra la fecha, que nos interesa bastante para responder a la pregunta. Una vez unida, filtramos la descripción del producto para quedarnos únicamente con los productos “plátano” y “banana”. Calculamos el precio medio del kilo por mes y representamos gráficamente ya que es una forma muy fácil de interpretar los datos, y de ver la evolución del precio de estos dos productos a lo largo del tiempo.




Figura 8: Evolucion mensual del precio por kilo

Con la Figura 8 podemos concluir que el precio de la banana se ha mantenido prácticamente estable a lo largo del año, presentando únicamente una leve caída puntual, de 1.5 euros a menos de un euro. En cambio, el precio del plátano ha mostrado una mayor variabilidad, de 2 euros incrementando a mas de 3 en menos de 4 meses, además cuenta con un aumento significativo seguido de una fuerte disminución, para luego volver a incrementar su valor.

9. ¿Cuál es la procedencia de los tickets? ¿Qué ciudad/ pueblo tiene un mayor número de tickets?

Podemos ver en la Figura 9, los diferentes municipios de los que proceden los tickets, hay una gran variedad de localidades diferentes, la mayoría de Valencia, pero alguna que otra de Alicante o de las Islas Baleares, incluso de Almeria (Vera, Garrucha). Podemos ver que la ciudad con el mayor número de tickets es Valencia, seguido de Alborai y después Burjassot, era algo que se podía esperar, la ciudad con más tickets es la ciudad de estudio y los alrededores, aparte de eso, podemos ver una gran cantidad de instancias de Alcoy y cercanías, y por último una gran variedad de provincias diferentes, sea tanto Valencia como Alicante, pero también Almeria y Baleares

10. Muestra mediante un diagrama el número de tickets recogidos cada día de las semana. ¿Si tuvieses que cerrar un día entre semana qué día lo harías?

Parece que lo obvio, según la Figura 10, sería cerrar los Domingos. Pero, por conocimiento del medio sabemos que la mayoría de las tiendas cierran ese mismo día; no es normal que las grandes cadenas de supermercados abran los Domingos. El siguiente mejor día para cerrar, es el jueves como podemos ver. Podríamos considerar también los martes o miércoles, ya que son los otros días con menos tickets.

En conclusión, la mayoría de personas no hace las compras entre semana, por lo que cerrar en uno de los días anteriormente mencionados es buena opción. Y, por otro lado, cerrar un fin de semana sería perjudicial.




Figura 9: Tickets por municipio




Figura 10: Tiquets por día

5 Conclusiones